

Ellenfél alapú támadások (FGSM, PGD)
implementációja
konvolúciós neurális hálózatokhoz
interaktív tesztkörnyezetben

Gabrity Gábor
Neptun kód: D9V09Z
2026. szeptember 13.

Nyilatkozat

Alulírott Gabrity Gábor (Neptun kód: D9V09Z), az Eötvös Loránd Tudományegyetem Informatikai Karának hallgatója kijelentem, hogy ezt a szakdolgozatot saját magam készítettem, és abban csak a megadott forrásokat használtam fel. Minden olyan részt, amelyet szó szerint vagy azonos tartalommal, de átfogalmazva más forrásból átvettem, egyértelműen, a forrás megadásával megjelöltem.

A dolgozat bírálója által hátrányos értékeléssel nem járó exkluzív elektronikus hozzáférést a benyújtástól számított két évig nem kérem.

Budapest, 2026. szeptember 13.

Gabrity Gábor s.k.
hallgató aláírása

Kivonat

Tartalomjegyzék

1. Rövidítés- és jelölésjegyzék	3
2. Bevezetés	4
2.1. Motiváció és a témaválasztás indoklása	4
2.2. A megoldandó feladat rövid, közérthető leírása	4
2.3. A dolgozat célja és hozzájárulásai	4
2.4. A dolgozat felépítése	4
3. Felhasználói dokumentáció	5
3.1. A megoldott probléma rövid megfogalmazása	5
3.2. A felhasznált módszerek rövid áttekintése	5
3.3. Rendszerkövetelmények	5
3.4. Telepítés és első indítás	5
3.5. A grafikus felhasználói felület bemutatása	5
3.6. Tipikus felhasználási forgatókönyvek	5
3.7. Hibaüzenetek és gyakori problémák	5
4. Fejlesztői dokumentáció	6
4.1. A probléma részletes specifikációja	6
4.2. Elméleti háttér és a használt fogalmak definíciója	6
4.3. Ellenfél alapú támadások áttekintése	6
4.4. FGSM (Fast Gradient Sign Method)	7
4.4.1. Matematikai háttér	7
4.4.2. Az algoritmus lépései	7
4.4.3. Célzott változat	7
4.4.4. Előnyök és korlátok	8
4.5. PGD (Projected Gradient Descent)	8
4.5.1. Matematikai háttér	8
4.5.2. Az algoritmus lépései	8
4.5.3. Célzott változat	9
4.5.4. Hiperparaméterek hatása	9
4.5.5. Előnyök és korlátok	9
4.6. Tervezési döntések és indoklásuk	9
4.7. Kapcsolódó munkák és további támadási módszerek	9
4.8. Védekezési stratégiák áttekintése	9
4.9. A rendszer architektúrája	9
4.10. A felhasznált technológiák	9
4.11. Az egyes komponensek megvalósítása	9

5. Tesztelés	10
5.1. Egységtesztek	10
5.2. Integrációs tesztek	13
5.2.1. GUI és támadási motor összekötése	13
5.3. Automatizált GUI tesztek	14
5.4. Funkcionális tesztek és felhasználói validáció	14
5.5. Teszteredmények és értelmezésük	16
5.6. A tesztelés korlátai	16
6. Összefoglalás	17
6.1. Elért eredmények	17
6.2. Következtetések	17
6.3. Továbbfejlesztési lehetőségek	17
Mellékletek	18

1. Rövidítés- és jelölésjegyzék

2. Bevezetés

2.1. Motiváció és a témaválasztás indoklása

2.2. A megoldandó feladat rövid, közérthető leírása

2.3. A dolgozat célja és hozzájárulásai

2.4. A dolgozat felépítése

3. Felhasználói dokumentáció

3.1. A megoldott probléma rövid megfogalmazása

3.2. A felhasznált módszerek rövid áttekintése

3.3. Rendszerkövetelmények

3.4. Telepítés és első indítás

3.5. A grafikus felhasználói felület bemutatása

3.6. Tipikus felhasználási forgatókönyvek

3.7. Hibaüzenetek és gyakori problémák

4. Fejlesztői dokumentáció

4.1. A probléma részletes specifikációja

Ebben a fejezetben a cél az megvalósítandó szofver által kitűzött cél leírása, a funkciók definiálása. Legyen adott egy f neurális háló alapú osztályozó modell, melynek x egy bemenete és y annak helyes címkéje. Az x bemenet ebben az esetben egy kép pixeleinek valamely három színű kódolása, vektoriális formában, az y kimenet pedig a kép osztályának indexe, például $y=42$ az agámák osztályát reprezentálja. Amennyiben a képhez tartozó y helyes címke nem ismert, úgy a modell által meghatározott legvalószínűbb címkét vesszük y -nak. Célunk, az x képre egy x_{adv} bemenetet állítsunk, mely az eredeti x – *tlsszemmelcsakalig lthat pertubcibanklnbzik, viszont a $y_{adv} = f(x_{adv})$ a y osztálytól viszont vagy eltr, vagy boxhoz frsnek nevezzük AI red teaming kontextusban.*

E szoftver célja a fenti ellenfél alapú támadó tesztkörnyezet szoftveres megvalósítása, különböző támadási algoritmusokkal (FGSM, PGD). A szoftver hozzáférést ad modellek széleskörű listájához - pytorchon keresztül. Beállíthatóak a futás paraméterei, például -epsilon, mely meghatározza a perturbáció maximális mértékekét, tehát azt, hogy egy pixelen legfeljebb mekkora változást tapasztalhatunk, azaz a változás felső határát. -cél osztály, y' ha a mód targeted -iteráció szám (PGD esetén hány lépésig engedjük futtatni az algoritmust)

A vizuális megjelenítés a céljai a következők: A fájlrendszerrel kiválasztott képet legördülő menüből kiválasztott modellel klasszifikálni tudjuk. Támadási algoritmus és paraméterek meghatározásával perturbációt és adversarial képet generálunk. Megjelenítjük az eredeti és adversarial képet, valamint a perturbációt és az adversarial képet is osztályozza. Vádekezésésként hozzáad tesztelhető

4.2. Elméleti háttér és a használt fogalmak definíciója

4.3. Ellenfél alapú támadások áttekintése

A mély neurális hálózatok – különösen a képfelismerésben alkalmazott konvolúciós architektúrák – rendkívül érzékenyek a bemeneti adatok apró, célzott módosításaira. Az ilyen módosításokat *ellenfél alapú perturbációknak* (adversarial perturbations) nevezzük, az ezeket előállító eljárásokat pedig *ellenfél alapú támadásoknak* (adversarial attacks) [1].

A támadások alapelve a következő: adott egy f osztályozó modell, egy x eredeti bemenet és annak helyes y címkéje. A cél egy olyan x_{adv} módosított bemenet előállítása, amelyre $f(x_{adv}) \neq y$, miközben a perturbáció $\delta = x_{adv} - x$ valamilyen norma szerint kicsi marad: $\|\delta\|_p \leq \epsilon$. A gyakorlatban leggyakrabban az ℓ_∞ normát alkalmazzák, amely a pixelenkénti maximális eltérést korlátozza.

A következő alfejezetekben a két legelterjedtebb gradiens alapú támadási módszer

mutatom be részletesen.

4.4. FGSM (Fast Gradient Sign Method)

Az FGSM algoritmust Goodfellow és társai javasolták 2015-ben [1]. Az eljárás egyetlen lépésben állítja elő a perturbációt a veszteségfüggvény bemenetre vonatkozó gradiensének előjelét felhasználva.

4.4.1. Matematikai háttér

Legyen $J(\theta, x, y)$ a modell veszteségfüggvénye (például keresztentropia), ahol θ a hálózat tanult paraméterei, x a bemeneti kép és y az eredeti címke. Az FGSM a veszteségfüggvény x -re vonatkozó gradiensét számítja ki visszaterjesztéssel (backpropagation), majd a perturbációt a gradiens előjelének ϵ -szorosával képezi:

$$x_{\text{adv}} = x + \epsilon \cdot \text{sign}(\nabla_x J(\theta, x, y))$$

A $\text{sign}(\cdot)$ függvény elemenként az előjelet adja vissza (-1 , 0 vagy $+1$), így a perturbáció minden pixel esetén pontosan $\pm\epsilon$ lesz. Ez biztosítja, hogy a módosítás az ℓ_∞ norma szerint pontosan ϵ nagyságú.

4.4.2. Az algoritmus lépései

1. Előreterjesztés (forward pass): a modell kiszámítja az x bemenethez tartozó predikciót és a veszteségfüggvény $J(\theta, x, y)$ értékét.
2. Visszaterjesztés (backward pass): kiszámítjuk a gradienst $\nabla_x J(\theta, x, y)$.
3. Perturbáció előállítás: $\delta = \epsilon \cdot \text{sign}(\nabla_x J(\theta, x, y))$.
4. Támadott kép: $x_{\text{adv}} = \text{clip}(x + \delta, 0, 1)$, ahol a clip függvény biztosítja, hogy a pixelértékek a $[0, 1]$ tartományban maradjanak.

4.4.3. Céltartó változat

Az alapváltozat (*non-targeted*) a helyes osztály veszteségét maximalizálja. A *targeted* változatban egy y_{target} célosztályt adunk meg, és a perturbációt úgy állítjuk elő, hogy a modell ebbe az osztályba sorolja a képet:

$$x_{\text{adv}} = x - \epsilon \cdot \text{sign}(\nabla_x J(\theta, x, y_{\text{target}}))$$

Az előjel megfordul, mert ebben az esetben a célosztályhoz tartozó veszteséget *minimalizáljuk*.

4.4.4. Előnyök és korlátok

Az FGSM fő előnye a sebessége: egyetlen gradiens-számítás elegendő. Hátránya, hogy egyetlen nagy lépést tesz, így kisebb ϵ értékek mellett gyakran kevésbé hatékony, mint az iteratív módszerek. Emellett a perturbáció iránya nem feltétlenül optimális, csupán a gradiens előjelét követi.

4.5. PGD (Projected Gradient Descent)

A PGD algoritmust Madry és társai vezették be 2018-ban [2] az FGSM iteratív általánosításaként. A módszert a szakirodalom gyakran a „legerősebb elsőrendű támadásnak” tekinti az ℓ_∞ korlátos perturbációk között.

4.5.1. Matematikai háttér

A PGD a következő iteratív frissítési szabályt alkalmazza, $t = 0, 1, \dots, T - 1$ lépésben:

$$x^{(t+1)} = \Pi_{\mathcal{B}_\epsilon(x)} \left(x^{(t)} + \alpha \cdot \text{sign}(\nabla_x J(\theta, x^{(t)}, y)) \right)$$

ahol:

- α a lépésméret (step size), jellemzően $\alpha < \epsilon$,
- T az iterációk száma,
- $\Pi_{\mathcal{B}_\epsilon(x)}$ a projekciós operátor, amely a módosított mintát visszavetíti az eredeti x körüli ϵ sugarú ℓ_∞ gömbbe:

$$\Pi_{\mathcal{B}_\epsilon(x)}(z) = \text{clip}(z, x - \epsilon, x + \epsilon)$$

4.5.2. Az algoritmus lépései

1. Kezdeti pont megválasztása: $x^{(0)}$ lehet maga az eredeti x , vagy egy véletlen pont az $\mathcal{B}_\epsilon(x)$ környezetből (random restart).
2. Iteráció ($t = 0, \dots, T - 1$):
 - (a) Előreterjesztés és veszteségszámítás az aktuális $x^{(t)}$ pontra.
 - (b) Gradiens számítása: $g^{(t)} = \nabla_x J(\theta, x^{(t)}, y)$.
 - (c) Lépés a gradiens irányába: $\hat{x}^{(t+1)} = x^{(t)} + \alpha \cdot \text{sign}(g^{(t)})$.
 - (d) Projekció: $x^{(t+1)} = \Pi_{\mathcal{B}_\epsilon(x)}(\hat{x}^{(t+1)})$.
 - (e) Pixelértékek vágása a $[0, 1]$ tartományba.
3. A végső támadott kép: $x_{\text{adv}} = x^{(T)}$.

4.5.3. Célzott változat

A targeted PGD a célzott FGSM-hez hasonlóan a célosztály veszteségét minimalizálja:

$$x^{(t+1)} = \Pi_{\mathcal{B}_\epsilon(x)} \left(x^{(t)} - \alpha \cdot \text{sign}(\nabla_x J(\theta, x^{(t)}, y_{\text{target}})) \right)$$

4.5.4. Hiperparaméterek hatása

A PGD viselkedését három fő hiperparaméter határozza meg:

- ϵ : a megengedett maximális perturbáció. Nagyobb ϵ erősebb támadást tesz lehetővé, de a módosítás emberi szemmel is láthatóvá válhat.
- α : a lépésmagyság. Túl kis α lassú konvergenciát eredményez, túl nagy α pedig instabilitáshoz vezethet. Tipikus választás: $\alpha = \epsilon/T$ vagy $\alpha = 2.5 \cdot \epsilon/T$.
- T : az iterációk száma. Több iteráció általában erősebb támadást eredményez, de növeli a számítási költséget.

4.5.5. Előnyök és korlátok

A PGD az FGSM-nél lényegesen erősebb támadásokat képes generálni, mivel több kis lépésben közelíti a lokális optimumot. A random restart technikával kombinálva különösen hatékony. Hátránya, hogy T -szer annyi gradiens-számítást igényel, mint az FGSM, így nagyobb a számítási költsége.

4.6. Tervezési döntések és indoklásuk

4.7. Kapcsolódó munkák és további támadási módszerek

4.8. Védekezési stratégiák áttekintése

4.9. A rendszer architektúrája

4.10. A felhasznált technológiák

4.11. Az egyes komponensek megvalósítása

5. Tesztelés

5.1. Egységtesztek

A program tesztkészletének felépítésénél a szakirodalomból ismert *tesztpiramisnak* nevezett hierarchiát követtem [3]. Ennek alapját a gyorsabb és kevés komponenst érintő tesztek, az egységtesztek képezik, melyek a lehető legkisebb elkülöníthető egységek tesztelését valósítják meg. Futási idejük jellemzően ezredmásodperces tartományban mozog és akár lefedhetik az input paraméterek teljes értékkészletét. Az elkészítésüknél fontos szempont a többi egységtől való függetlenség (izoláció) és az perifériáktól való függetlenség, I/O, adatbázis, hálózat, stb. Ezeknek a teszteknek az elkészítésére érdemes nagy figyelmet fordítani, mivel a korai szakaszban feltárt hibák javítása általában lényegesen olcsóbb, mint a későbbi, integráció vagy éles környezetben felfedezettéké.

Az egységtesztek tudatosan nem a valódi, előtanított ResNet50/MobileNetV2 modelleket használják. Az `attack_engine` teszteknel egy `tiny_model` fixture ad egy 5 osztályos, 8×8 pixeles bemenetet feldolgozó, egyetlen lineáris rétegből álló hálót. Ez a döntés a tesztek sebességét (a valódi háló letöltése és felépítése másodperces nagyságrendű lenne) és izoláltságát szolgálja: a teszt kizárólag a saját kódunk logikáját vizsgálja, nem a harmadik féltől származó architektúra pontosságát.

Minden véletlent felhasználó fixture (pl. a bemeneti képet generáló `sample_image_tensor`) maga hívja meg a `torch.manual_seed`-et közvetlenül az adat előállítás előtt, így a determinizmus független a fixture-ök végrehajtási sorrendjétől. Az egységtesztek szintjén nem támadási sikerrátát mérünk (ehhez sok mintás, statisztikai kiértékelés kellene), hanem az algoritmusok tulajdonságait ellenőrizzük konkrét, kis méretű bemeneteken.

Ebben a részben a számosságuk miatt nem mutatom be az összes egységtesztet, csak a középpontban álló `attack_engine.py` modult mivel ez valósítja meg az alkalmazás lényegi logikáját (az FGSM és PGD algoritmusokat, valamint az ezeket kiszolgáló `predict()` és `attack()` függvényeket).

A `predict()` és a `diszpécser (attack())` tesztjei

test_predict_returns_topk_shapes: Ellenőrzi, hogy `topk=3` esetén a visszaadott valószínűség- és index-tenzor alakja $(1, 3)$, azaz a batch- és k -dimenzió megfelel a kérésnek.

test_predict_returns_valid_distribution: A `topk=5` valószínűségek mindegyike a $[0, 1]$ intervallumba esik, és – mivel az 5 osztályos `tiny_model` minden osztálya lekérdezésre kerül – összegük 1,0-ra `allclose`. Ez a softmax kimenet valódi valószínűségi eloszlás voltát igazolja.

`test_predict_topk_returns_highest_first`: A visszaadott valószínűségek csökkenő sorrendben szerepelnek ($\text{probs}[0, i] \geq \text{probs}[0, i + 1]$), vagyis a `topk` valóban a legnagyobb konfidenciájú osztályokat adja vissza, még hozzá rendezetten.

`test_attack_unknown_method_raises`: Határeset: egy nem létező módszernév ("NEM VALID") megadásakor `ValueError`-t vár, mielőtt bármilyen gradiensszámítás történne – a bemenet-validáció a drága számítás előtt fut le.

`test_attack_fgsm_ignores_iterations_argument`: Annak ellenére, hogy a hívó `iterations=99`-et ad át, FGSM esetén a visszaadott `AttackResult.iterations_run` értéke 1 – igazolva, hogy az FGSM valóban egy lépéses, és a paramétert a diszpécser figyelmen kívül hagyja erre a módszerre.

`test_attack_pgd_reports_requested_iteration_count`: PGD esetén a kért iterációszám (4) változatlanul megjelenik az `iterations_run` mezőben, alátámasztva, hogy a diszpécser a paramétert továbbadja a `_pgd` implementációnak.

`test_attack_fgsm_dispatches_only_to_fgsm`: `mock.patch(..., wraps=_fgsm)` és `wraps=_pgd` spy-okkal figyeli a hívásokat: `method="FGSM"` esetén `_fgsm.assert_called_once()` és `_pgd.assert_not_called()` teljesül. A `wraps` paraméter miatt a valódi implementáció is lefut, tehát az `AttackResult` összeállítása is ellenőrzött marad.

`test_attack_pgd_dispatches_only_to_pgd`: Az előző teszt tükörképe: `method="PGD"` esetén kizárólag `_pgd` hívódik meg, `_fgsm` nem. A két teszt együtt zárja ki, hogy a diszpécser valamelyik ágon „átcsorogva” mindkét algoritmust lefuttassa.

Az FGSM implementáció (`_fgsm`) tesztjei

`test_fgsm_targeted_steps_opposite_direction_of_untargeted`: Azonos bemeneten és ϵ mellett a `targeted` és `non-targeted` perturbáció pontosan ellentétes előjelű ($x_{\text{untargeted}} - x = -(x_{\text{targeted}} - x)$), ami közvetlenül a matematikai definícióból (a gradiens előjelének megfordításából) következik.

`test_fgsm_clamps_to_valid_pixel_range`: Szélsőséges bemenet (csupa nulla pixel) és nagy $\epsilon = 0,5$ mellett is a kimenet minden eleme a $[0, 1]$ tartományban marad – igazolva, hogy a `clamp` lépés ténylegesen érvényesül, nem csak elméletben szerepel a specifikációban.

`test_fgsm_result_is_detached_from_autograd`: A visszaadott tenzor `requires_grad` attribútuma `False`.

`test_fgsm_result_has_no_graph_history`: Szigorúbb bizonyíték az előzőnél: `grad_fn` is `None` és `is_leaf` is `True` egyszerre teljesül, ami kizárja azt az esetet is, amikor egy tenzor `requires_grad` értéke hamis, de mégis egy számítási gráf levele marad rejtett hivatkozásokkal.

`test_fgsm_zero_epsilon_returns_original`: Határeset: $\epsilon = 0$ esetén a perturbáció nulla, a kimenet `allclose` az eredeti képpel – az algoritmus degenerált esetben identitásként viselkedik.

`test_fgsm_untargeted_reduces_confidence_in_true_label`: Viselkedési bizonyíték: a `predict()`-en keresztül lekérdezett, a valódi címkéhez tartozó konfidencia a támadás után szigorúan kisebb, mint előtte – ez nem csak a perturbáció létezését, hanem annak tényleges hatását igazolja a modell kimenetére.

`test_fgsm_targeted_increases_confidence_in_target_label`: A `targeted` változat tükörpárja: a mesterségesen kiválasztott célosztály konfidenciája nő a támadás hatására, alátámasztva, hogy a `targeted` mód valóban a célosztály felé tereli a predikciót, nem csupán „valamerre” téveszti meg a modellt.

A PGD implementáció (`_pgd`) tesztjei

`test_pgd_result_stays_within_epsilon_ball`: Mérsékelt lépésméret ($\alpha = 0,02$) mellett a végső perturbáció minden pixelre $|\delta| \leq \epsilon + 10^{-6}$ (a tolerancia a lebegőpontos kerekítést kompenzálja) – ez az ℓ_∞ -gömbbe való projekció alapvető helyességét igazolja.

`test_pgd_hits_ball_when_step_too_large`: Szándékosan irreálisan nagy lépésméretet ($\alpha = 10,0 \gg \epsilon = 0,02$) ad meg, ami minden iterációban túllövést okoz; ilyenkor a projekciós `clamp`-nek kell egyedül biztosítania a korlátot, ezért a tesztben a végső $|\delta|$ pontosan (nem csak $\leq$) ϵ -nak adódik minden pixelen – ez a projekció, nem a lépésméret helyes megválasztása általi korlátozottságot bizonyítja.

`test_pgd_clamps_to_valid_pixel_range`: A pixeltartomány-korlátozás ugyanúgy teljesül PGD esetén is, mint FGSM-nél: szélsőséges (nulla) bemeneten és nagy ϵ mellett a kimenet a $[0, 1]$ tartományban marad.

`test_pgd_result_has_no_graph_history`: Ugyanaz az erős `detach`-bizonyíték (`grad_fn is None` és `is_leaf is True`), mint FGSM esetén – fontos, mert a PGD több iterációt is végez, minden lépésben új `requires_grad_(True)` hívással, így könnyebben „elszivároghatna” egy hivatkozás a gráfra, ha a ciklus végén elmaradna a leválasztás.

`test_pgd_zero_epsilon_returns_original`: Határeset: $\epsilon = 0$ esetén – annak ellenére, hogy több iteráció is lefut – a projekció minden lépésben nulla szélességű intervallumra szorítja a perturbációt, így a végeredmény megegyezik az eredeti képpel.

`test_pgd_untargeted_reduces_confidence_in_true_label`: Viselkedési bizonyíték `predict()`-en keresztül: a valódi címke konfidenciája több iteráció után is csökken – ugyanaz az elv, mint FGSM-nél, de itt azt is igazolja, hogy az iteratív frissítés nem „rontja el” a kumulatív hatást.

`test_pgd_targeted_increases_confidence_in_target_label`: A targeted PGD a cél-osztály konfidenciáját növeli – ugyanazon tulajdonságpár (non-targeted csökkenti/targeted növeli a releváns konfidenciát) FGSM-re és PGD-re is parametrizált formában lett tesztelve (@pytest.mark.parametrize), elkerülve, hogy csak az egyik algoritmusra íródjon le a viselkedés.

5.2. Integrációs tesztek

5.2.1. GUI és támadási motor összekötése

Az integrációs réteg feladata annak ellenőrzése, hogy az `app_interface.py` eseménykezelői helyesen építik-e fel az `AttackContext`-et a ténylegesen betöltött `ModelBundle`-ból, és a `attack_engine.attack()` hívás eredménye helyesen jelenik-e meg a felületen (kép- és predikció-frissítés). Ez a réteg már nem mockolja a modellt, de a valódi felhasználói interakciót (egérekattintás, csúszka-mozgatás) sem szimulálja még – azt a GUI-tesztek rétege végzi.

5.3. Automatizált GUI tesztek

A GUI tesztek a felhasználói felületet magát, a ténylegesen megjelenő ablakot és widgeteket vizsgálják, programozott módon szimulálva a felhasználói interakciókat, majd ellenőrizi, hogy a felület a várt módon reagál-e. Ez a legfelső, egyben legköltségesebb és leglassabb réteg a tesztpiramisban, hiszen minden egyes esethez fel kell építeni a teljes grafikus felületet – ezért csak kevés, a legfontosabb felhasználói forgatókönyvet lefedő tesztesetre érdemes szorítkozni, a részletesebb logikai ellenőrzést az alsóbb rétegekre (egység- és integrációs tesztek) hagyva.

5.4. Funkcionális tesztek és felhasználói validáció

A grafikus felület funkcionális, „fekete doboz” tesztéseit a felhasználói forgatókönyvek alapján, *Given–When–Then* formában fogalmazom meg. Az alábbi esetek a tényleges felhasználói felületének elemeihez (gombok, csúszkák, célosztály-kereső) igazodnak, és kézi (manuális) végrehajtásra tervezettek.

- **Kép betöltése a „Load Image” gombbal**

AS A: felhasználó I WANT TO: egy képet betölteni a vizsgálathoz

GIVEN: az alkalmazás elindítva, még nincs kép betöltve

WHEN: a „Load Image” gombra kattint, majd egy érvényes képfájlt választ ki

THEN: az „Original” képmezőben megjelenik a beolvasott, 224×224 -re vágott kép, és alatta a top-3 predikció és konfidencia frissül

- **Modell váltása betöltött kép mellett**

AS A: felhasználó I WANT TO: összehasonlítani, hogy más architektúra hogyan látja a képet

GIVEN: egy kép már be van töltve, az „Original” predikciós panel ki van töltve

WHEN: a modell-választó legördülőben „MobileNetV2”-t választ „ResNet50” helyett

THEN: az „Original” predikciók újraszámolódnak az új modellel; ha korábban már futott támadás, az „Adversarial” predikciók is frissülnek

- **Non-targeted támadás végrehajtása**

AS A: felhasználó I WANT TO: általános tévesztést előidézni a modellben

GIVEN: kép betöltve, „Targeted attack” jelölőnégyzet kikapcsolva, ϵ és iterációs szám csúszkák beállítva

WHEN: az „Attack” gombra kattint

THEN: a státuszsor „Running...” majd „Attack complete” üzenetet mutat, megjelenik a felnagyított perturbáció és a támadott kép, és az „Adversarial” predikciós panelen az eredeti top-1 osztály konfidenciája jellemzően csökken

- **Targeted támadás célosztály kereséssel**

AS A: felhasználó I WANT TO: egy konkrét osztályra rávenni a modellt

GIVEN: kép betöltve, a célosztály-kereső mezőbe elkezd gépelni egy osztálynevet

WHEN: a szűrt listából kiválaszt egy osztályt, majd az „Attack” gombra kattint

THEN: a „Targeted attack” jelölőnégyzet automatikusan bejelölődik, a státuszsor a kiválasztott osztály nevét mutatja, és a támadás után a célosztály konfidenciája nő

- **Epsilon csúszka élő előnézete FGSM módban**

AS A: felhasználó I WANT TO: interaktívan látni, hogyan változik a perturbáció erőssége

GIVEN: FGSM módszerrel már lefutott egy támadás (a gradiens előjele cache-elve van)

WHEN: az ϵ csúszkát új értékre húzza, PGD-re váltás nélkül

THEN: a perturbáció és az adversarial kép új gradiens-számítás *nélkül*, azonnal újraszámolódik a cache-elt előjel alapján

- **Attack gomb kép nélkül**

AS A: felhasználó I WANT TO: (véletlenül) támadást indítani kép betöltése előtt

GIVEN: az alkalmazás elindítva, nincs betöltött kép

WHEN: az „Attack” gombra kattint

THEN: egy „No image” információs párbeszédablak jelenik meg, a támadás nem indul el

- **Védekezési szűrő alkalmazása (Blur / JPEG)**

AS A: felhasználó I WANT TO: megvizsgálni, hogy egy egyszerű szűrő semlegesíti-e a zajt

GIVEN: egy sikeres támadás után az „Adversarial” kép elérhető

WHEN: a „Defend (Blur)” vagy „Defend (JPEG)” gombra kattint

THEN: az „Adversarial” képmező a szűrt képre frissül, és a predikciós panel az újraosztályozott (a szűrés után kapott) eredményeket mutatja

- **Defend gomb adversarial kép nélkül**

AS A: felhasználó I WANT TO: (véletlenül) védekezést alkalmazni támadás előtt

GIVEN: kép be van töltve, de még nem futott támadás

WHEN: valamelyik „Defend” gombra kattint

THEN: egy „No adversarial” információs párbeszédablak jelenik meg, semmilyen kép nem változik

- **Reset gomb**

AS A: felhasználó I WANT TO: új kísérletet kezdeni ugyanazzal a képpel

GIVEN: egy támadás és esetleg egy védekezés már lefutott

WHEN: a „Reset” gombra kattint

THEN: a perturbáció és az „Adversarial” képmező üresre vált, az „Adversarial” predikciós panel névtelen („—”) állapotba áll vissza, az „Original” kép és predikciói változatlanok maradnak

- **Hibakezelés támadás közben**

AS A: felhasználó I WANT TO: érthető visszajelzést kapni, ha a támadás valamiért meghiúsul

GIVEN: kép betöltve, a háttérszálon futó `_attack_worker` kivételt dob (pl. eszközhiba miatt)

WHEN: az „Attack” gombra kattint

THEN: egy „Attack failed” hibaablak jelenik meg a teljes veremkiíratással, a státuszsor „Attack failed.” szöveget mutat, az alkalmazás nem fagy le

5.5. Teszteredmények és értelmezésük

5.6. A tesztelés korlátai

6. Összefoglalás

6.1. Elért eredmények

6.2. Következtetések

6.3. Továbbfejlesztési lehetőségek

Mellékletek

Hivatkozások

- [1] Ian J. Goodfellow, Jonathon Shlens, Christian Szegedy. *Explaining and Harnessing Adversarial Examples*. arXiv:1412.6572, 2015.
- [2] Aleksander Madry, Aleksandar Makelov, Ludwig Schmidt, Dimitris Tsipras, Adrian Vladu. *Towards Deep Learning Models Resistant to Adversarial Attacks*. arXiv:1706.06083, 2018.
- [3] Martin Fowler. *TestPyramid*. martinowler.com, 2012. <https://martinfowler.com/bliki/TestPyramid.html>
- [4] Gintare Karolina Dziugaite, Zoubin Ghahramani, Daniel M. Roy. *A study of the effect of JPG compression on adversarial images*. arXiv:1608.00853, 2016.