

Ellenfél alapú támadások (FGSM, PGD)
implementációja
konvolúciós neurális hálózatokhoz
interaktív tesztkörnyezetben

Gabrity Gábor
Neptun kód: D9V09Z
2026. szeptember 19.

Nyilatkozat

Alulírott Gabrity Gábor (Neptun kód: D9V09Z), az Eötvös Loránd Tudományegyetem Informatikai Karának hallgatója kijelentem, hogy ezt a szakdolgozatot saját magam készítettem, és abban csak a megadott forrásokat használtam fel. Minden olyan részt, amelyet szó szerint vagy azonos tartalommal, de átfogalmazva más forrásból átvettem, egyértelműen, a forrás megadásával megjelöltem.

A dolgozat bírálója által hátrányos értékeléssel nem járó exkluzív elektronikus hozzáférést a benyújtástól számított két évig nem kérem.

Budapest, 2026. szeptember 19.

Gabrity Gábor s.k.
hallgató aláírása

Kivonat

Tartalomjegyzék

1. Rövidítés- és jelölésjegyzék	3
2. Bevezetés	4
2.1. Motiváció és a témaválasztás indoklása	4
2.2. A megoldandó feladat rövid, közérthető leírása	4
2.3. A dolgozat célja és hozzájárulásai	4
2.4. A dolgozat felépítése	4
3. Felhasználói dokumentáció	5
3.1. A megoldott probléma rövid megfogalmazása	5
3.2. A felhasznált módszerek rövid áttekintése	5
3.3. Rendszerkövetelmények	5
3.4. Telepítés és első indítás	5
3.5. A grafikus felhasználói felület bemutatása	5
3.6. Tipikus felhasználási forgatókönyvek	5
3.7. Hibaüzenetek és gyakori problémák	5
4. Fejlesztői dokumentáció	6
4.1. A probléma részletes specifikációja	6
4.1.1. A felhasználói funkciók vázlatos áttekintése	6
4.2. Elméleti háttér és a használt fogalmak definíciója	7
4.3. Ellenfél alapú támadások áttekintése	7
4.4. FGSM (Fast Gradient Sign Method)	7
4.5. PGD (Projected Gradient Descent)	7
4.5.1. Hiperparaméterek hatása	7
4.5.2. Előnyök és korlátok	8
4.6. Tervezési döntések és indoklásuk	8
4.7. Kapcsolódó munkák és további támadási módszerek	8
4.8. Védekezési stratégiák áttekintése	8
4.9. A rendszer architektúrája	8
4.10. A felhasznált technológiák	8
4.11. Az egyes komponensek megvalósítása	8
5. Tesztelés	9
5.1. Egységtesztek	9
5.2. Integrációs tesztek	12
5.2.1. GUI és támadási motor összekötése	12
5.3. Automatizált GUI tesztek	13
5.4. Funkcionális tesztek és felhasználói validáció	13

5.5. Teszteredmények és értelmezésük	15
5.6. A tesztelés korlátai	15
6. Összefoglalás	16
6.1. Elért eredmények	16
6.2. Következtetések	16
6.3. Továbbfejlesztési lehetőségek	16
Mellékletek	17

1. Rövidítés- és jelölésjegyzék

2. Bevezetés

2.1. Motiváció és a témaválasztás indoklása

2.2. A megoldandó feladat rövid, közérthető leírása

2.3. A dolgozat célja és hozzájárulásai

2.4. A dolgozat felépítése

3. Felhasználói dokumentáció

3.1. A megoldott probléma rövid megfogalmazása

3.2. A felhasznált módszerek rövid áttekintése

3.3. Rendszerkövetelmények

3.4. Telepítés és első indítás

3.5. A grafikus felhasználói felület bemutatása

3.6. Tipikus felhasználási forgatókönyvek

3.7. Hibaüzenetek és gyakori problémák

4. Fejlesztői dokumentáció

4.1. A probléma részletes specifikációja

Ebben a fejezetben szeretném a megvalósítandó szoftver célját és funkcióit definiálni. Legyen adott egy f_θ neurális háló alapú osztályozó modell, melynek x egy bemenete és y annak helyes címkéje. Az x bemenet ebben az esetben egy kép pixeleinek valamely három színű kódolása, vektoriális formában, az y pedig a kép helyes osztályának indexe, például $y = 42$ az agámák osztályát reprezentálja. Amennyiben a képhez tartozó y helyes címke nem ismert, úgy a modell által meghatározott legvalószínűbb címkét $\hat{y}$ -nal jelöljük, és ezt használjuk referenciacímkeként. Célunk az x képre egy x_{adv} bemenet előállítása, mely az eredeti x -től szemmel csak alig látható perturbációban különbözik, viszont a modell által adott $\hat{y}_{\text{adv}} = \arg \max_i f_\theta(x_{\text{adv}})_i$ predikció a referenciaosztálytól eltér, vagy a klasszifikáció elbizonytalanodik. Alapvetően két támadási módot különböztetünk meg, az ún. targeted és non-targeted módot. Non-targeted esetben a támadás célja minél jobban elbizonytalanítani a helyes osztályozást, tehát hogy agáma helyett bármi mást mutasson. Targeted módban azt szeretnénk, hogy egy kijelölt y_{target} osztály irányába változzon a képünk. (pl. komodói varánusz) A támadás feltétele, hogy az f_θ modell gradienseihez és paramétereire teljes hozzáférésünk legyen. Ezt white-box hozzáférésnek nevezzük AI red teaming kontextusban.

E szoftver célja a fenti ellenfél alapú támadó tesztkörnyezet szoftveres megvalósítása, különböző támadási algoritmusokkal (FGSM, PGD). A szoftver a PyTorch (torchvision) előtanított modelljeire épül, mely architektúra tetszőleges torchvision-moddal bővíthető. Jelenleg kettő van integrálva (ResNet50, MobileNetV2). Beállíthatóak a futás paramétere:

- modell: ResNet50 vagy MobileNetV2, amelyen a támadást végrehajtjuk,
- ϵ , mely meghatározza a perturbáció maximális mértékét, tehát azt, hogy egy pixelen legfeljebb mekkora változást tapasztalhatunk, azaz a változás felső határát,
- cél osztály, y_{target} , ha a mód targeted,
- iterációszám (PGD esetén hány lépésig engedjük futtatni az algoritmust).

4.1.1. A felhasználói funkciók vázlatos áttekintése

A fenti specifikációt a szoftver az alábbi, a felhasználó számára közvetlenül elérhető funkciókkal valósítja meg:

- a fájlrendszerről kiválasztott képet legördülő menüből kiválasztott modellel klasszifikáljuk,

- támadási algoritmus és paraméterek meghatározásával perturbációt és adversarial képet generálunk,
- megjelenítjük az eredeti képet, a perturbációt és az adversarial képet, továbbá mindkét (eredeti és adversarial) képet osztályozzuk is,
- a védekezési modulban JPEG-tömörítést vagy más képfeldolgozási szűrőt alkalmazhatunk az adversarial perturbáció hatásának utólagos csökkentésére vagy semlegesítésére.

4.2. Elméleti háttér és a használt fogalmak definíciója

4.2.1. Az osztályozó modell és a logitok

Jelöljük $f_\theta(x) = z$ -vel a modell outputjaként előállt valós számok tömbjét, ahol $z \in \mathbb{R}^C$ és C az osztályok száma. (ImageNet esetén $C = 1000$) Ezt logit vektornak is nevezzük, mely elnevezés a logisztikus regresszióból származik, ahol a $\text{logit}(p) = \ln \frac{p}{1-p}$ függvény egy valószínűséget képez le a valós számegyenesre. A z_i komponensek páronkénti különbsége éppen az i -edik és j -edik osztály esélyhányadosának logaritmusával egyezik meg, $z_i - z_j = \ln \frac{p_i}{p_j}$, innen ez az elnevezés.

4.2.2. Valószínűségek és a modell predikciója

Mivel a z logitok önmagukban nem valószínűségek, a softmax függvénnyel alakítjuk át őket valószínűségi eloszlássá:

$$p_i = \text{softmax}(z)_i = \frac{e^{z_i}}{\sum_{j=1}^C e^{z_j}}, \quad i = 1, \dots, C.$$

Tehát p_i a modell szerint annak a valószínűsége, hogy x az i -edik osztályba tartozik. A modell által meghatározott legvalószínűbb osztály indexét a legnagyobb valószínűségű komponens alapján kapjuk:

$$\hat{y} = \arg \max_i p_i.$$

4.2.3. Veszteségfüggvény és bemeneti gradiens

A $J(\theta, x, y)$ veszteségfüggvény a modell predikciója és a megadott helyes címke közötti eltérést méri. Esetünkben ez a keresztentrópia-veszteség

$$J(\theta, x, y) = -\log \frac{e^{z_y}}{\sum_{i=1}^C e^{z_i}},$$

ahol $z = f_\theta(x)$ a logitvektor és y a helyes osztály indexe. A gradiens a súlyokra nézve, $\nabla_\theta J(\theta, x, y)$, az a gradiensvektor, amelyet a backpropagation során a tanításban használ-

lunk a súlyok módosítására. Itt most a gradiensszámítást egy további lépéssel a legutolsó, bemeneti réteig visszük, és megkapjuk a bemeneti vektorra vonatkozó érzékenységet, $\nabla_x J(\theta, x, y)$. Ez a mennyiség azt mutatja meg, hogy egy adott bemeneti pixel vagy jellemző változása milyen mértékben befolyásolja a veszteséget, ezért központi szerepe lesz a későbbiekben az adversarial példák generálásának és az algoritmusok leírásának.

4.2.4. Perturbáció és normakorlát

Pár mondat az adversarial képek definiálásánál használt L_p normákról. Egy perturbált kép általában az

$$x_{\text{adv}} = x + \delta$$

formában írható le, ahol δ a zaj, vagyis a képpontokban okozott változás. A perturbáció nagyságát egy norma szerint korlátozzuk:

$$\|\delta\|_p \leq \epsilon.$$

Ez esetünkben nagyon kézenfekvő, mivel a bemeneti kép minden pixelén a változást külön-külön korlátozza.

4.3. Ellenfél alapú támadások áttekintése

A mély neurális hálók, köztük a képfelismerő modellek különösen érzékenyek a bemeneti adatok kicsi ám célzott módosításaira. Az ilyen módosításokat ellenfél alapú perturbációknak nevezzük. Ezeknek a támadásoknak két algoritmusát fogjuk itt átvenni, melyek a taxonómiában a korábban említett white-box támadások közé tartoznak. A következő fejezetekben egy egylépéses ellenfél alapú támadást mutatunk be (FGSM), utána erre építve egy többlépéses algoritmust (PGD).

4.4. FGSM (Fast Gradient Sign Method)

Az FGSM algoritmust Goodfellow és társai javasolták a google-nél dolgozva. Az előző fejezetben megjegyeztem, hogy a $\nabla_x J(\theta, x, y)$ célfüggvény gradiense az input értékre való érzékenységet jelenti. Adja magát, hogy léptessük el a gradienssel ellenkező irányba az inputot, ami várhatóan rontani fogja a célfüggvény értékét. Ehhez azt feltételezzük, hogy a modell az x kellően kis környezetében lineárisan viselkedik. Az FGSM algoritmusban az elmozdítást egyszerűen csak a sign előjel-függvény epszilonszorosával tesszük meg, tehát nem vesszük figyelembe a gradiens által adott érzékenységet, csak az irányt. Viszont ilyen módon az epsilon x sign maximálizálja az epsilon költségvetésünket minden x_i -re. Tehát az FGSM adversarial képet e módon kapjuk meg: $x_{\text{adv}} = x + \text{sign}(\nabla_x J(\theta, x, y)) \cdot \epsilon$

4.4.1. Célzott változat

Az alapváltozat a megadott helyes osztály veszteségét igyekszik maximalizálni, tehát minél inkább mást mutasson mint ami a képen van. A célzott változatnál y_{target} célosztályt adunk meg és azt szeretnénk, hogy a modell ebbe az osztályba sorolja az adversarial képet. $x_{\text{adv}} = x - \text{sign } \nabla J(x, y_{\text{target}})$ Tehát a képlet csak annyiban változik, hogy távolodás helyett közeledni szeretnénk és y helyett y_{target} -hoz.

4.4.2. Előnyök és korlátok

Mivel a gradienst a tanításban is használt backpropagation segítségével hatékonyan tudjuk kiszámolni, ezért a támadás gyors. Hátránya, hogy csak egy durva lépést tesz a megfelelő irányba, így adódhat, hogy kicsi változást érünk el vele az osztályozásban, például az iteratív módszerekhez képest.

4.5. PGD (Projected Gradient Descent)

4.5.1. Hiperparaméterek hatása

A PGD viselkedését három fő hiperparaméter határozza meg:

- ϵ : a megengedett maximális perturbáció. Nagyobb ϵ erősebb támadást tesz lehetővé, de a módosítás emberi szemmel is láthatóvá válhat.
- α : a lépésnagyság. Túl kis α lassú konvergenciát eredményez, túl nagy α pedig instabilitáshoz vezethet. Tipikus választás: $\alpha = \epsilon/T$ vagy $\alpha = 2.5 \cdot \epsilon/T$.
- T : az iterációk száma. Több iteráció általában erősebb támadást eredményez, de növeli a számítási költséget.

4.5.2. Előnyök és korlátok

A PGD az FGSM-nél lényegesen erősebb támadásokat képes generálni, mivel több kis lépésben közelíti a lokális optimumot. A random restart technikával kombinálva különösen hatékony. Hátránya, hogy T -szer annyi gradiens-számítást igényel, mint az FGSM, így nagyobb a számítási költsége.

- 4.6. Tervezési döntések és indoklásuk
- 4.7. Kapcsolódó munkák és további támadási módszerek
- 4.8. Védekezési stratégiák áttekintése
- 4.9. A rendszer architektúrája
- 4.10. A felhasznált technológiák
- 4.11. Az egyes komponensek megvalósítása

5. Tesztelés

5.1. Egységtesztek

A program tesztkészletének felépítésénél a szakirodalomból ismert *tesztpiramisnak* nevezett hierarchiát követtem [3]. Ennek alapját a gyorsabb és kevés komponenst érintő tesztek, az egységtesztek képezik, melyek a lehető legkisebb elkülöníthető egységek tesztelését valósítják meg. Futási idejük jellemzően ezredmásodperces tartományban mozog és akár lefedhetik az input paraméterek teljes értékkészletét. Az elkészítésüknél fontos szempont a többi egységtől való függetlenség (izoláció) és az perifériáktól való függetlenség, I/O, adatbázis, hálózat, stb. Ezeknek a teszteknek az elkészítésére érdemes nagy figyelmet fordítani, mivel a korai szakaszban feltárt hibák javítása általában lényegesen olcsóbb, mint a későbbi, integráció vagy éles környezetben felfedezetté.

Az egységtesztek tudatosan nem a valódi, előtanított ResNet50/MobileNetV2 modelleket használják. Az `attack_engine` teszteknel egy `tiny_model` fixture ad egy 5 osztályos, 8×8 pixeles bemenetet feldolgozó, egyetlen lineáris rétegből álló hálót. Ez a döntés a tesztek sebességét (a valódi háló letöltése és felépítése másodperces nagyságrendű lenne) és izoláltságát szolgálja: a teszt kizárólag a saját kódunk logikáját vizsgálja, nem a harmadik féltől származó architektúra pontosságát.

Minden véletlent felhasználó fixture (pl. a bemeneti képet generáló `sample_image_tensor`) maga hívja meg a `torch.manual_seed`-et közvetlenül az adat előállítás előtt, így a determinizmus független a fixture-ök végrehajtási sorrendjétől. Az egységtesztek szintjén nem támadási sikerrátát mérünk (ehhez sok mintás, statisztikai kiértékelés kellene), hanem az algoritmusok tulajdonságait ellenőrizzük konkrét, kis méretű bemeneteken.

Ebben a részben a számosságuk miatt nem mutatom be az összes egységtesztet, csak a középpontban álló `attack_engine.py` modult mivel ez valósítja meg az alkalmazás lényegi logikáját (az FGSM és PGD algoritmusokat, valamint az ezeket kiszolgáló `predict()` és `attack()` függvényeket).

A `predict()` és a diszpécser (`attack()`) tesztjei

`test_predict_returns_topk_shapes`: Ellenőrzi, hogy `topk=3` esetén a visszaadott valószínűség- és index-tenzor alakja $(1, 3)$, azaz a batch- és k -dimenzió megfelel a kérésnek.

`test_predict_returns_valid_distribution`: A `topk=5` valószínűségek mindegyike a $[0, 1]$ intervallumba esik, és – mivel az 5 osztályos `tiny_model` minden osztálya lekérdezésre kerül – összegük 1,0-ra `allclose`. Ez a softmax kimenet valódi valószínűségi eloszlás voltát igazolja.

`test_predict_topk_returns_highest_first`: A visszaadott valószínűségek csökkenő sorrendben szerepelnek ($\text{probs}[0, i] \geq \text{probs}[0, i + 1]$), vagyis a `topk` valóban a legnagyobb konfidenciájú osztályokat adja vissza, még hozzá rendezetten.

`test_attack_unknown_method_raises`: Határeset: egy nem létező módszernév ("NEM VALID") megadásakor `ValueError`-t vár, mielőtt bármilyen gradiensszámítás történne – a bemenet-validáció a drága számítás előtt fut le.

`test_attack_fgsm_ignores_iterations_argument`: Annak ellenére, hogy a hívó `iterations=99`-et ad át, FGSM esetén a visszaadott `AttackResult.iterations_run` értéke 1 – igazolva, hogy az FGSM valóban egylépéses, és a paramétert a diszpécser figyelmen kívül hagyja erre a módszerre.

`test_attack_pgd_reports_requested_iteration_count`: PGD esetén a kért iterációszám (4) változatlanul megjelenik az `iterations_run` mezőben, alátámasztva, hogy a diszpécser a paramétert továbbadja a `_pgd` implementációnak.

`test_attack_fgsm_dispatches_only_to_fgsm`: `mock.patch(..., wraps=_fgsm)` és `wraps=_pgd` spy-okkal figyeli a hívásokat: `method="FGSM"` esetén `_fgsm.assert_called_once()` és `_pgd.assert_not_called()` teljesül. A `wraps` paraméter miatt a valódi implementáció is lefut, tehát az `AttackResult` összeállítása is ellenőrzött marad.

`test_attack_pgd_dispatches_only_to_pgd`: Az előző teszt tükörképe: `method="PGD"` esetén kizárólag `_pgd` hívódik meg, `_fgsm` nem. A két teszt együtt zárja ki, hogy a diszpécser valamelyik ágon „átcsorogva” mindkét algoritmust lefuttassa.

Az FGSM implementáció (`_fgsm`) tesztjei

`test_fgsm_targeted_steps_opposite_direction_of_untargeted`: Azonos bemeneten és ϵ mellett a `targeted` és `non-targeted` perturbáció pontosan ellentétes előjelű ($x_{\text{untargeted}} - x = -(x_{\text{targeted}} - x)$), ami közvetlenül a matematikai definícióból (a gradiens előjelének megfordításából) következik.

`test_fgsm_clamps_to_valid_pixel_range`: Szélsőséges bemenet (csupa nulla pixel) és nagy $\epsilon = 0,5$ mellett is a kimenet minden eleme a $[0, 1]$ tartományban marad – igazolva, hogy a `clamp` lépés ténylegesen érvényesül, nem csak elméletben szerepel a specifikációban.

`test_fgsm_result_is_detached_from_autograd`: A visszaadott tenzor `requires_grad` attribútuma `False`.

`test_fgsm_result_has_no_graph_history`: Szigorúbb bizonyíték az előzőnél: `grad_fn` `is None` és `is_leaf` `is True` egyszerre teljesül, ami kizárja azt az esetet is, amikor egy tenzor `requires_grad` értéke hamis, de mégis egy számítási gráf levele marad rejtett hivatkozásokkal.

`test_fgsm_zero_epsilon_returns_original`: Határeset: $\epsilon = 0$ esetén a perturbáció nulla, a kimenet `allclose` az eredeti képpel – az algoritmus degenerált esetben identitásként viselkedik.

`test_fgsm_untargeted_reduces_confidence_in_true_label`: Viselkedési bizonyíték: a `predict()`-en keresztül lekérdezett, a valódi címkéhez tartozó konfidencia a támadás után szigorúan kisebb, mint előtte – ez nem csak a perturbáció létezését, hanem annak tényleges hatását igazolja a modell kimenetére.

`test_fgsm_targeted_increases_confidence_in_target_label`: A `targeted` változat tükörpárja: a mesterségesen kiválasztott célosztály konfidenciája nő a támadás hatására, alátámasztva, hogy a `targeted` mód valóban a célosztály felé tereli a predikciót, nem csupán „valamerre” téveszti meg a modellt.

A PGD implementáció (`_pgd`) tesztjei

`test_pgd_result_stays_within_epsilon_ball`: Mérsékelt lépésméret ($\alpha = 0,02$) mellett a végső perturbáció minden pixelre $|\delta| \leq \epsilon + 10^{-6}$ (a tolerancia a lebegőpontos kerekítést kompenzálja) – ez az ℓ_∞ -gömbbe való projekció alapvető helyességét igazolja.

`test_pgd_hits_ball_when_step_too_large`: Szándékosan irreálisan nagy lépésméretet ($\alpha = 10,0 \gg \epsilon = 0,02$) ad meg, ami minden iterációban túllövést okoz; ilyenkor a projekciós `clamp`-nek kell egyedül biztosítania a korlátot, ezért a tesztben a végső $|\delta|$ pontosan (nem csak $\leq$) ϵ -nak adódik minden pixelen – ez a projekció, nem a lépésméret helyes megválasztása általi korlátozottságot bizonyítja.

`test_pgd_clamps_to_valid_pixel_range`: A pixeltartomány-korlátozás ugyanúgy teljesül PGD esetén is, mint FGSM-nél: szélsőséges (nulla) bemeneten és nagy ϵ mellett a kimenet a $[0, 1]$ tartományban marad.

`test_pgd_result_has_no_graph_history`: Ugyanaz az erős detach-bizonyíték (`grad_fn is None` és `is_leaf is True`), mint FGSM esetén – fontos, mert a PGD több iterációt is végez, minden lépésben új `requires_grad_(True)` hívással, így könnyebben „elszívárogathatna” egy hivatkozás a gráfra, ha a ciklus végén elmaradna a leválasztás.

`test_pgd_zero_epsilon_returns_original`: Határeset: $\epsilon = 0$ esetén – annak ellenére, hogy több iteráció is lefut – a projekció minden lépésben nulla szélességű intervallumra szorítja a perturbációt, így a végeredmény megegyezik az eredeti képpel.

`test_pgd_untargeted_reduces_confidence_in_true_label`: Viselkedési bizonyíték `predict()`-en keresztül: a valódi címke konfidenciája több iteráció után is csökken – ugyanaz az elv, mint FGSM-nél, de itt azt is igazolja, hogy az iteratív frissítés nem „rontja el” a kumulatív hatást.

`test_pgd_targeted_increases_confidence_in_target_label`: A targeted PGD a cél-osztály konfidenciáját növeli – ugyanazon tulajdonságpár (non-targeted csökkenti/targeted növeli a releváns konfidenciát) FGSM-re és PGD-re is parametrizált formában lett tesztelve (@pytest.mark.parametrize), elkerülve, hogy csak az egyik algoritmusra íródjon le a viselkedés.

5.2. Integrációs tesztek

5.2.1. GUI és támadási motor összekötése

Az integrációs réteg feladata annak ellenőrzése, hogy az `app_interface.py` eseménykezelői helyesen építik-e fel az `AttackContext`-et a ténylegesen betöltött `ModelBundle`-ból, és a `attack_engine.attack()` hívás eredménye helyesen jelenik-e meg a felületen (kép- és predikció-frissítés). Ez a réteg már nem mockolja a modellt, de a valódi felhasználói interakciót (egérekattintás, csúszka-mozgatás) sem szimulálja még – azt a GUI-tesztek rétege végzi.

5.3. Automatizált GUI tesztek

A GUI tesztek a felhasználói felületet magát, a ténylegesen megjelenő ablakot és widgeteket vizsgálják, programozott módon szimulálva a felhasználói interakciókat, majd ellenőrizi, hogy a felület a várt módon reagál-e. Ez a legfelső, egyben legköltségesebb és leglassabb réteg a tesztpiramisban, hiszen minden egyes esethez fel kell építeni a teljes grafikus felületet – ezért csak kevés, a legfontosabb felhasználói forgatókönyvet lefedő tesztesetre érdemes szorítkozni, a részletesebb logikai ellenőrzést az alsóbb rétegekre (egység- és integrációs tesztek) hagyva.

5.4. Funkcionális tesztek és felhasználói validáció

A grafikus felület funkcionális, „fekete doboz” tesztéseit a felhasználói forgatókönyvek alapján, *Given–When–Then* formában fogalmazom meg. Az alábbi esetek a tényleges felhasználói felületének elemeihez (gombok, csúszkák, célosztály-kereső) igazodnak, és kézi (manuális) végrehajtásra tervezettek.

- **Kép betöltése a „Load Image” gombbal**

AS A: felhasználó I WANT TO: egy képet betölteni a vizsgálathoz

GIVEN: az alkalmazás elindítva, még nincs kép betöltve

WHEN: a „Load Image” gombra kattint, majd egy érvényes képfájlt választ ki

THEN: az „Original” képmezőben megjelenik a beolvasott, 224×224 -re vágott kép, és alatta a top-3 predikció és konfidencia frissül

- **Modell váltása betöltött kép mellett**

AS A: felhasználó I WANT TO: összehasonlítani, hogy más architektúra hogyan látja a képet

GIVEN: egy kép már be van töltve, az „Original” predikciós panel ki van töltve

WHEN: a modell-választó legördülőben „MobileNetV2”-t választ „ResNet50” helyett

THEN: az „Original” predikciók újraszámolódnak az új modellel; ha korábban már futott támadás, az „Adversarial” predikciók is frissülnek

- **Non-targeted támadás végrehajtása**

AS A: felhasználó I WANT TO: általános tévesztést előidézni a modellben

GIVEN: kép betöltve, „Targeted attack” jelölőnégyzet kikapcsolva, ϵ és iterációs szám csúszkák beállítva

WHEN: az „Attack” gombra kattint

THEN: a státuszsor „Running...” majd „Attack complete” üzenetet mutat, megjelenik a felnagyított perturbáció és a támadott kép, és az „Adversarial” predikciós panelen az eredeti top-1 osztály konfidenciája jellemzően csökken

- **Targeted támadás célozástal kereséssel**

AS A: felhasználó I WANT TO: egy konkrét osztályra rávenni a modellt

GIVEN: kép betöltve, a célozástal-kereső mezőbe elkezd gépelni egy osztálynevet

WHEN: a szűrt listából kiválaszt egy osztályt, majd az „Attack” gombra kattint

THEN: a „Targeted attack” jelölőnégyzet automatikusan bejelölődik, a státuszsor a kiválasztott osztály nevét mutatja, és a támadás után a célozástal konfidenciája nő

- **Epsilon csúszka élő előnézete FGSM módban**

AS A: felhasználó I WANT TO: interaktívan látni, hogyan változik a perturbáció erőssége

GIVEN: FGSM módszerrel már lefutott egy támadás (a gradiens előjele cache-elve van)

WHEN: az ϵ csúszkát új értékre húzza, PGD-re váltás nélkül

THEN: a perturbáció és az adversarial kép új gradiens-számítás *nélkül*, azonnal újraszámolódik a cache-elt előjel alapján

- **Attack gomb kép nélkül**

AS A: felhasználó I WANT TO: (véletlenül) támadást indítani kép betöltése előtt

GIVEN: az alkalmazás elindítva, nincs betöltött kép

WHEN: az „Attack” gombra kattint

THEN: egy „No image” információs párbeszédablak jelenik meg, a támadás nem indul el

- **Védekezési szűrő alkalmazása (Blur / JPEG)**

AS A: felhasználó I WANT TO: megvizsgálni, hogy egy egyszerű szűrő semlegesíti-e a zajt

GIVEN: egy sikeres támadás után az „Adversarial” kép elérhető

WHEN: a „Defend (Blur)” vagy „Defend (JPEG)” gombra kattint

THEN: az „Adversarial” képmező a szűrt képre frissül, és a predikciós panel az újraosztályozott (a szűrés után kapott) eredményeket mutatja

- **Defend gomb adversarial kép nélkül**

AS A: felhasználó I WANT TO: (véletlenül) védekezést alkalmazni támadás előtt

GIVEN: kép be van töltve, de még nem futott támadás

WHEN: valamelyik „Defend” gombra kattint

THEN: egy „No adversarial” információs párbeszédablak jelenik meg, semmilyen kép nem változik

- **Reset gomb**

AS A: felhasználó I WANT TO: új kísérletet kezdeni ugyanazzal a képpel

GIVEN: egy támadás és esetleg egy védekezés már lefutott

WHEN: a „Reset” gombra kattint

THEN: a perturbáció és az „Adversarial” képmező üresre vált, az „Adversarial” predikciós panel névtelen („—”) állapotba áll vissza, az „Original” kép és predikciói változatlanok maradnak

- **Hibakezelés támadás közben**

AS A: felhasználó I WANT TO: érthető visszajelzést kapni, ha a támadás valamiért meghiúsul

GIVEN: kép betöltve, a háttérszálon futó `_attack_worker` kivételt dob (pl. eszközhiba miatt)

WHEN: az „Attack” gombra kattint

THEN: egy „Attack failed” hibaablak jelenik meg a teljes veremkiíratással, a státuszsor „Attack failed.” szöveget mutat, az alkalmazás nem fagy le

5.5. Teszteredmények és értelmezésük

5.6. A tesztelés korlátai

6. Összefoglalás

6.1. Elért eredmények

6.2. Következtetések

6.3. Továbbfejlesztési lehetőségek

Mellékletek

Hivatkozások

- [1] Ian J. Goodfellow, Jonathon Shlens, Christian Szegedy. *Explaining and Harnessing Adversarial Examples*. arXiv:1412.6572, 2015.
- [2] Aleksander Madry, Aleksandar Makelov, Ludwig Schmidt, Dimitris Tsipras, Adrian Vladu. *Towards Deep Learning Models Resistant to Adversarial Attacks*. arXiv:1706.06083, 2018.
- [3] Martin Fowler. *TestPyramid*. martinowler.com, 2012. <https://martinfowler.com/bliki/TestPyramid.html>
- [4] Gintare Karolina Dziugaite, Zoubin Ghahramani, Daniel M. Roy. *A study of the effect of JPG compression on adversarial images*. arXiv:1608.00853, 2016.